Hazem Ilahi

Élève ingénieur en Data Science & IA — Machine Learning | MLOps | LLM / RAG

Tunis, Tunisie | +216 97 111 410 | hazem.ilahi@esprit.tn | linkedin.com/in/hazem-ilahi-016a7a315 | github.com/Dyaus2

Recherche un stage de fin d'études (PFE) de 6 mois à partir de janvier/février 2027 — mobilité internationale

Stage obligatoire du cursus — convention de stage tripartite signée par ESPRIT

PROFIL

Élève ingénieur en dernière année à ESPRIT (diplôme prévu en 2027), spécialité Science des Données & IA, avec une expérience pratique en machine learning, MLOps et systèmes LLM/RAG. Lors de mon dernier stage, j'ai conçu la couche de détection par ML d'un framework d'investigation numérique : détection d'anomalies et classifieur calibré par gradient boosting, portant la couverture des étapes d'attaque de 18 % à 84 % à 1 % de faux positifs, avec une chaîne de réentraînement hebdomadaire (champion/challenger, surveillance de la dérive, retour arrière automatique). Je recherche un stage appliqué en data science / ML engineering : détection d'anomalies, analyse prédictive, applications LLM/RAG, MLOps, prévision.

FORMATION

ESPRIT — École Supérieure Privée d'Ingénierie et de Technologies 2023 – 2027 (diplôme prévu)

Cycle ingénieur, Science des Données & Intelligence Artificielle — dernière année ; stage de fin d'études obligatoire de 6 mois (PFE) à partir de janvier/février 2027 *Ariana, Tunisie*

IPEIT — Institut Préparatoire aux Études d'Ingénieurs de Tunis 2020 – 2023

Cycle préparatoire, Physique-Chimie *Montfleury, Tunisie*

EXPÉRIENCE PROFESSIONNELLE

Stagiaire Machine Learning — NEXT STEP IT (département SOC) Juillet 2026 – Septembre 2026

ATOR DFIR — couche de détection de menaces par ML et chaîne MLOps *Charguia 1, Tunisie*

- Couverture des étapes d'attaque sur un corpus public d'émulation d'adversaire portée de 18 % (règles Sigma seules) à 84 % (règles + ML) à 1 % de faux positifs ; 135 des 168 étapes manquées par les règles récupérées.
- Conception et intégration de la couche ML d'ATOR DFIR, framework d'investigation numérique et de chasse aux menaces sur postes Windows/Linux, au-dessus d'un moteur de règles YARA/Sigma développé par l'équipe sécurité.
- Classifieur de vraisemblance de menace (gradient boosting par histogrammes, calibration de Platt) : PR-AUC de 0,927 contre 0,278 pour les règles, erreur de calibration de 1,6 %, validation croisée à 5 plis groupée par capture.
- Détection d'anomalies non supervisée (Isolation Forest, 300 arbres) : 23 des 25 premiers signalements du benchmark sont de vraies étapes d'attaque ; classifieur de tactique MITRE ATT&CK avec seuil de confiance (79,7 % de précision).
- Jeu d'entraînement constitué à partir de 115 captures d'attaques publiques (Empire, Covenant, Mimikatz, Metasploit) converties par ETL vers le schéma du framework et labellisées par filiation de processus ; 110 variables comportementales par processus, calculées par un code unique partagé entre entraînement et production.
- Chaîne MLOps hebdomadaire : snapshot, ETL, réentraînement, 14 critères de qualité hors ligne, essai silencieux champion/challenger de 7 jours sur le trafic réel, déploiement atomique avec contrôle canari, retour arrière automatique, surveillance de la dérive (PSI) et protection du réentraînement contre l'empoisonnement de la référence.
- Intégration : 10 endpoints REST et page de chasse aux menaces pour analystes SOC (priorités P1–P4, verdicts) ; plus de 500 tests automatisés, dont des tests d'injection de pannes garantissant qu'une défaillance ML n'interrompt jamais la détection par règles.

Stack : Python 3.13, scikit-learn, pandas, NumPy, SQLite, FastAPI, Jinja2, pytest, Git

Stagiaire Développeur — NEXT STEP IT Juillet 2025 – Septembre 2025

Plateforme web de génération de rapports SOC (stage en binôme) *Charguia 1, Tunisie*

- Conception et développement en binôme d'une plateforme web Python/Django destinée aux analystes SOC, avec une interface UI/UX intuitive.
- Automatisation de la génération des rapports SOC, en remplacement de la rédaction manuelle répétitive ; préparation de la solution en vue d'un futur déploiement.

Stack : Python, Django, HTML/CSS, Git

PROJETS

Garage Augmenté — Assistant multi-agents RAG de pré-diagnostic automobile 2026 – 2027

Projet d'équipe, ESPRIT — responsable de la base de connaissances et de la couche de recherche

- Pipeline RAG modulaire sur Qdrant : expansion de requêtes multilingue (français, anglais, arabe tunisien), recherche hybride dense BGE-M3 + BM25 fusionnée par reciprocal rank fusion, filtrage marque/modèle/année, reranking par cross-encoder et consultation exacte de 9 533 codes défaut OBD.
- 7 collecteurs Python reprenables (catalogues XML, API JSON, sitemaps, routes de données Next.js) : 2 019 manuels du propriétaire uniques (≈ 697 000 pages, 26 marques), 73 % de sources constructeurs officielles, 54 des 56 modèles prioritaires couverts (issus d'une étude du marché automobile tunisien, immatriculations 2015–2026).
- Préparation du corpus : déduplication SHA-256, OCR Tesseract de ≈ 18 500 pages, normalisation des métadonnées véhicule en 364 familles de modèles, étiquetage thématique ; index principal de 98 000 unités (≈ 39 M tokens).
- Service FastAPI pour le workflow n8n, banc d'ablation (hit@k, MRR) et paquet de transfert documenté (Docker Compose, scripts d'ingestion et d'évaluation) pour la machine GPU hébergeant l'index.

Stack : Python, Qdrant, BGE-M3, BM25, PyMuPDF, Tesseract, FastAPI, Docker Compose, n8n

Kadastra — Plateforme d'intelligence immobilière basée sur l'IA 2026

Projet d'équipe (Data Crunchers), ESPRIT — méthodologie Microsoft TDSP

- Pipeline de bout en bout pour le marché immobilier tunisien : collecte de ≈ 26 000 annonces (Mubawab, Tayara), estimation de prix par XGBoost, génération de contrats et de scénarios d'investissement.
- Suppression d'une fuite de données dans les variables du modèle ; calage des constantes financières sur la législation tunisienne et les taux de la BCT ; déploiement full-stack FastAPI, Django, React et Docker.

Show, Attend and Tell — Génération automatique de légendes d'images (vision + NLP) 2026

Projet de Deep Learning — PyTorch, Flickr8k

- Reproduction du modèle encodeur-décodeur à attention (CNN + LSTM), puis extensions : encodeur ViT, reranking du beam search par CLIP et fine-tuning de BLIP ; évaluation BLEU et visualisation des cartes d'attention.

DressMe — Assistant de mode personnel intelligent pour le marché tunisien 2026 – 2027

Projet d'équipe (Advanced Data Science Project), ESPRIT — phase de conception, Design Thinking

- Recherche utilisateur (17 répondants, 6 personas) traduite en 5 objectifs métier et data science avec métriques et feuille de route en 3 versions ; architecture en 5 couches (passerelle FastAPI, Redis Streams, PostgreSQL/FAISS).
- Spécification de 6 pipelines ML (ingestion YOLO + SAM 2 + Qwen3-VL, compatibilité de tenues BPR sur Polyvore, recommandeur Two-Tower + LightGBM, agent de revente ReAct) et d'une stratégie d'explicabilité (TreeSHAP, LIME, contrefactuels).

Analyse de séries temporelles — Dépenses de construction aux États-Unis 2026

Projet de modélisation statistique en R

- Analyse des dépenses de construction résidentielle (U.S. Census Bureau) en trois phases : analyse graphique, ajustement déterministe (tendances polynomiales), modélisation ARIMA/SARIMA avec diagnostics et prévisions.

COMPÉTENCES TECHNIQUES

Langages: Python, R, SQL, C/C++, Java, PHP
ML / DL: scikit-learn, XGBoost, PyTorch, TensorFlow, Keras ; détection d'anomalies, classification, calibration, validation croisée groupée ; vision par ordinateur (CNN, ViT, CLIP, BLIP) ; séries temporelles (ARIMA/SARIMA)
LLM / RAG / NLP: pipelines RAG, Qdrant, embeddings BGE-M3, BM25, recherche hybride, reranking par cross-encoder, évaluation hit@k / MRR, Transformers
MLOps: réentraînement automatisé, registre de modèles, déploiement champion/challenger, surveillance de la dérive (PSI), critères de qualité, déploiement canari et retour arrière, pytest
Data: pandas, NumPy, ETL, web scraping, OCR (Tesseract), SQLite, Power BI, Tableau
Cloud & déploiement: AWS (Cloud Foundations), Docker, Docker Compose, FastAPI, Django, Flask, Spring Boot, Symfony, API REST, n8n, Git
Méthodologies: Microsoft TDSP, CRISP-DM, Design Thinking, Agile/Scrum

CERTIFICATIONS

- AWS Cloud Foundations — Amazon Web Services (badge, novembre 2026)
- Fundamentals of Deep Learning — NVIDIA (2026)
- Applications of AI for Anomaly Detection — NVIDIA (2026)
- Building Transformer-Based Natural Language Processing Applications — NVIDIA (2026)
- CCNA 2 : Switching, Routing, and Wireless Essentials (SRWE) — Cisco Networking Academy (2025)

LANGUES

Arabe : langue maternelle | Français : courant (niveau avancé, usage professionnel) | Anglais : courant